

LISTA DE CONTEÚDOS

I. Introdução

II. Metodologia

III. Base de Dados Utilizadas

IV. Modelos Utilizados

V. Resultados Obtidos e Discussão

VI. Considerações Finais

VII. Trabalho Futuro

VIII. Referências

Problema em estudo: No processo tradicional de compra em supermercados, pesar frutas exige que o cliente insira manualmente o código correspondente, o que pode ser inconveniente e propenso a erros.


Solução proposta: Com a instalação de uma câmara equipada com um modelo de classificação automatizado, o sistema identifica a fruta de forma rápida e precisa, eliminando a necessidade de inserir códigos manualmente.

Objetivos do projeto:


- Desenvolver modelos de *machine learning* capazes de realizar a classificação das frutas/legumes. Para realizar esta tarefa, serão utilizadas Redes Neurais Convolucionais (CNNs) pré-treinadas.



Passo 1: Recolha das Imagens



Passo 2: Criação do Dataset



Utilização da
ferramenta
Roboflow para
anotação das
imagens



Total de imagens capturadas: 1048

Passo 3: Pré-processamento das Imagens



Pré-processamento das imagens e Data Augmentation, gerando o Dataset final

Dataset Split

TRAIN SET

70%

1377 Images

VALID SET

20%

393 Images

TEST SET

10%

196 Images

Total de imagens após
Data Augmentation:
1966

Dataset da turma

Tipo	Quantidade
Banana	180
Batata	180
Dióspiro	180
Laranja	180
Limão	180
Maça	180
Pera	180
Kiwi	180


Dataset do grupo

Tipo	Quantidade
Banana	408
Batata	389
Dióspiro	426
Laranja	341
Kiwi	417

Base de Dados do Grupo


Modelo ResNet50 V2

Relatório de Classificação:				
	precision	recall	f1-score	support
Banana	1.00	1.00	1.00	39
Batata	1.00	0.95	0.98	44
Diospiro	1.00	1.00	1.00	32
Kiwi	0.90	1.00	0.95	18
Laranja	1.00	1.00	1.00	63
accuracy			0.99	196
macro avg	0.98	0.99	0.98	196
weighted avg	0.99	0.99	0.99	196




Modelo Inception V3

Relatório de Classificação:				
	precision	recall	f1-score	support
Banana	1.00	1.00	1.00	39
Batata	1.00	0.89	0.94	44
Diospiro	1.00	1.00	1.00	32
Kiwi	0.78	1.00	0.88	18
Laranja	1.00	1.00	1.00	63
accuracy			0.97	196
macro avg	0.96	0.98	0.96	196
weighted avg	0.98	0.97	0.98	196




Base de Dados do Grupo

Modelo ResNet50 V2





Modelo Inception V3





Base de Dados do Grupo

Modelo ResNet50 V2




Modelo Inception V3



Base de Dados da Turma


Modelo ResNet50 V2

Relatório de Classificação:				
	precision	recall	f1-score	support
banana	1.00	1.00	1.00	30
batata	1.00	1.00	1.00	30
diospiros	1.00	0.97	0.98	30
kiwi	1.00	1.00	1.00	30
laranjas	0.97	1.00	0.98	30
limao	1.00	1.00	1.00	30
maca	1.00	1.00	1.00	30
pera	1.00	1.00	1.00	30
accuracy			1.00	240
macro avg	1.00	1.00	1.00	240
weighted avg	1.00	1.00	1.00	240




Modelo Inception V3

Relatório de Classificação:				
	precision	recall	f1-score	support
banana	1.00	1.00	1.00	30
batata	1.00	0.97	0.98	30
diospiros	1.00	0.97	0.98	30
kiwi	0.91	1.00	0.95	30
laranjas	0.88	0.97	0.92	30
limao	0.93	0.87	0.90	30
maca	1.00	1.00	1.00	30
pera	1.00	0.93	0.97	30
accuracy			0.96	240
macro avg	0.96	0.96	0.96	240
weighted avg	0.96	0.96	0.96	240




Base de Dados da Turma

Modelo ResNet50 V2





Modelo Inception V3





Base de Dados da Turma

Modelo ResNet50 V2



Modelo Inception V3



Única Imagem mal classificada com o modelo ResNet50 V2 no dataset da turma

Análise com a técnica LIME (Método de XAI)




Imagem classificada com o modelo Inception V3 no dataset da turma

Análise com a técnica LIME (Método de XAI)



Imagem mal classificada com o modelo Inception V3 no dataset da turma

Análise com a técnica LIME (Método de XAI)





Imagem muito bem classificada com o modelo Inception V3 no dataset do grupo

Análise com a técnica LIME (Método de XAI)



Algumas considerações relevantes:

- No geral, o *dataset* da Turma trouxe vantagens a nível de eficiência do modelo Resnet50 V2.
- Como no dataset da Turma as classes estão organizadas de uma forma mais equilibrada, o Resnet50 v2 tornou-se mais eficiente.
- O modelo Inception V3, em relação ao Grupo obteve melhores resultados em comparação ao da Turma, devido ao dataset do Grupo conter apenas 5 classes, o que diminuiu a complexidade de aprendizagem do modelo.




Próximos passos:

- Combater o problema de overfitting no modelo ResNet50 V2 na base de dados do grupo. Ajuste de Hiperparâmetros.
- Desenvolver um modelo mais eficiente para esta tarefa de classificação.
 - Testar o modelo Visual Transformer (ViT).
 - Testar o modelo VGG16.

Referências:

- <https://roboflow.com/>
- <https://colab.google/>
- <https://keras.io/api/applications/resnet/>
- <https://keras.io/api/applications/inceptionv3/>

Relatório de Classificação:				
	precision	recall	f1-score	support
banana	1.00	1.00	1.00	30
batata	0.97	1.00	0.98	30
diospiros	1.00	1.00	1.00	30
kiwi	0.96	0.90	0.93	30
laranjas	0.88	1.00	0.94	30
limao	0.96	0.87	0.91	30
maca	1.00	1.00	1.00	30
pera	0.97	0.97	0.97	30
accuracy			0.97	240
macro avg	0.97	0.97	0.97	240
weighted avg	0.97	0.97	0.97	240



Algumas das imagens mal classificadas

Verdadeiro: limao
Previsto: laranjas



Verdadeiro: limao
Previsto: laranjas




Verdadeiro: limao
Previsto: laranjas





Verdadeiro: limao
Previsto: laranjas





Base de Dados da Turma - Modelo MobileNet



VIT x CNN

Recurso	Transformador de Visão (ViT)	Rede Neural Convolucional (CNN)
Extração de recursos	Global, usando patches de imagem não sobrepostos	Local, através de filtros convolucionais
Arquitetura	Baseado em transformadores	Construído em torno de camadas convolucionais
Requisito de dados	Requer mais dados para um desempenho ideal	Menos intensivo em dados, pode ter bom desempenho em conjuntos de dados menores
Custo Computacional	Mais alto, devido à necessidade de pré-treinamento em larga escala	Relativamente mais baixo
Adequação do caso de uso	Destaca-se em tarefas que exigem compreensão de padrões globais	Ideal para tarefas onde as características locais são significativas




Imagem Original




Imagem dividida em patches


Image size: 224 X 224
Patch size: 16 X 16
Patches per image: 196
Elements per patch: 768

Base de Dados da Turma - Modelo VIT - vit_tiny_patch16_224



Classification Report:				
	precision	recall	f1-score	support
banana	1.00	1.00	1.00	30
batata	1.00	1.00	1.00	30
diospiros	1.00	1.00	1.00	30
kiwi	1.00	1.00	1.00	30
laranjas	1.00	1.00	1.00	30
limao	1.00	1.00	1.00	30
maca	1.00	1.00	1.00	30
pera	1.00	1.00	1.00	30
accuracy			1.00	240
macro avg	1.00	1.00	1.00	240
weighted avg	1.00	1.00	1.00	240



Base de Dados da Turma - Modelo VIT - vit_tiny_patch16_224



Base de Dados da Turma - Modelo ViT - vit_tiny_patch16_224



- **Desempenho Superior do Vision Transformer (ViT):** Os resultados mostram que o ViT superou as CNNs em classificação de imagens, possivelmente graças à sua capacidade de capturar relacionamentos globais de forma mais eficiente.
- **Impacto e Perspectivas Futuras:** A superioridade do ViT sugere uma tendência de adoção de modelos baseados em atenção, com potencial para estudos que combinem suas vantagens com as CNNs.

